

Particion Heterogenea CPU-GPU para Entrenamiento Profundo

Monografia Doctoral (Borrador Evolutivo)

Doctorando: Zephyr

19 de marzo de 2026

Índice general

1. Introduccion, Problema y Diseno de la Investigacion	2
1.1. 1.1 Contexto e introduccion	2
1.2. 1.2 Motivacion tecnica y relevancia cientifica	2
1.3. 1.3 Planteamiento formal del problema	2
1.4. 1.4 Hipotesis de investigacion	3
1.5. 1.5 Objetivos general y especificos	3
1.6. 1.6 Alcance decisional fijado (resultado de Fase 0)	3
1.7. 1.7 Metodologia general y validacion	3
1.8. 1.8 Contribucion cientifica	3
1.9. 1.9 Organizacion del documento	4
2. Fundamentos Teoricos y Estado del Arte	5
2.1. 2.1 Entrenamiento de redes profundas y grafos computacionales	5
2.2. 2.2 Arquitecturas heterogeneas CPU-GPU y jerarquias de memoria	5
2.3. 2.3 Transferencia de datos, solapamiento y comunicacion	5
2.4. 2.4 Estrategias de gestion de memoria	6
2.5. 2.5 Optimizacion declarativa: ILP en sistemas computacionales	6
2.6. 2.6 Estado del arte y vacios de investigacion	6
3. Arquitectura Metodologica del Sistema	7
3.1. 3.1 Vision general del pipeline experimental	7
3.2. 3.2 Estructura modular del software	7
3.3. 3.3 Contrato de artefactos y trazabilidad	7
3.4. 3.4 Definicion de plan y su representacion	7
3.5. 3.5 Criterios de validez y riesgos metodologicos iniciales	8

4. Profiling Empirico para Particion Heterogenea CPU-GPU	9
4.1. 4.1 Motivacion empirica y preguntas de medicion	9
4.2. 4.2 Arquitectura de instrumentacion	9
4.3. 4.3 Modelo de energia y carga computacional	9
4.4. 4.4 Politica de precision y validez	9
4.5. 4.5 Extraccion estructural del grafo	10
4.6. 4.6 Modelo de transferencia consciente de arista	10
4.7. 4.7 Agregacion estadistica robusta	10
4.8. 4.8 Validez experimental y reproducibilidad	10
5. Formulacion ILP Robusta para Particion Heterogenea CPU-GPU	11
5.1. 5.1 Introduccion y alcance del modelo (congelado en Fase 0)	11
5.2. 5.2 Notacion formal	11
5.3. 5.3 Variables de decision	11
5.4. 5.4 Funcion objetivo multicriterio	11
5.5. 5.5 Linealizaciones exactas y restricciones	12
5.6. 5.6 Robustificacion estadistica	12
5.7. 5.7 Integracion multi-hardware	12
5.8. 5.8 Complejidad y trazabilidad	12
5.9. 5.9 Validacion comparativa contra baselines (habilitada por Fase 1)	12
5.10. 5.10 Estudios de sensibilidad (habilitados por Fase 1)	12
5.11. 5.11 Ablaciones formales (habilitadas por Fase 1)	13
5.12. 5.12 Extension avanzada: persistencia de activaciones y rematerializacion (Fase 4)	13
5.13. 5.13 Amenazas a la validez	13
6. Ejecucion Hibrida, Simulacion y Validacion Experimental	14
6.1. 6.1 Introduccion: cierre del bucle planificacion-ejecucion	14
6.2. 6.2 Representacion formal del plan de ejecucion (Fase 2)	14
6.3. 6.3 Simulador hibrido: arquitectura y validacion topologica (Fase 2)	14
6.4. 6.4 Estudio de prediccion: latencia, memoria y costos de transferencia (Fase 2)	15
6.5. 6.5 Implementacion del ejecutor hibrido en PyTorch (Fase 3)	15
6.6. 6.6 Baselines reales y comparativos experimentales (Fase 3)	15
6.7. 6.7 Prediccion frente a observacion: contraste operacional (Fase 3)	15
6.8. 6.8 Exactitud final del modelo y estabilidad de convergencia (Fase 3-5) . .	15

6.9.	6.9 Extensiones con persistencia de activaciones y scheduling asincrono (Fase 4)	15
6.10.	6.10 Analisis integrado de resultados y limites experimentales (Fase 5)	16
7.	Conclusiones, Limites y Trabajo Futuro	17
7.1.	7.1 Sintesis de resultados frente a la hipotesis	17
7.2.	7.2 Contribuciones metodologicas y de sistemas	17
7.3.	7.3 Limites del modelo y del protocolo experimental	17
7.4.	7.4 Lineas de trabajo futuro	17

Capítulo 1

Introduccion, Problema y Diseno de la Investigacion

1.1. 1.1 Contexto e introduccion

El entrenamiento profundo sobre arquitectura heterogenea CPU-GPU presenta una tension estructural entre capacidad de computo, disponibilidad de memoria y costo de comunicacion. Este trabajo parte de esa tension como problema central y la aborda desde una perspectiva de sistemas, no solo de rendimiento puntual.

1.2. 1.2 Motivacion tecnica y relevancia cientifica

La motivacion tecnica surge del uso suboptimo de la CPU en flujos que dependen casi exclusivamente de GPU, aun cuando la CPU puede absorber fracciones de carga bajo restricciones controladas. La relevancia cientifica reside en formalizar dicha redistribucion con criterios auditables y reproducibles.

1.3. 1.3 Planteamiento formal del problema

Se define un problema de particion de capas sobre dos dispositivos, sujeto a restricciones de memoria y dependencia topologica, con objetivo multicriterio en tiempo, energia y transferencia. La formulacion se instancia sobre perfiles empiricos por capa y estructura de grafo del modelo.

1.4. 1.4 Hipotesis de investigacion

La hipotesis principal establece que una asignacion optimizada y robustificada puede mejorar el objetivo global frente a politicas simples, manteniendo la validez operacional del entrenamiento.

1.5. 1.5 Objetivos general y especificos

El objetivo general es disenar y validar un sistema integral de particion heterogenea para entrenamiento profundo. Los objetivos especificos abarcan instrumentacion robusta, formulacion ILP, comparacion contra baselines, simulacion previa a ejecucion real y validacion final en infraestructura heterogenea.

1.6. 1.6 Alcance decisional fijado (resultado de Fase 0)

El alcance metodologico vigente fija asignacion independiente para *forward/backward*, persistencia de activaciones como variable de decision y soporte asincrono para *streaming/prefetching*. Estas decisiones son vinculantes para las fases subsiguientes.

1.7. 1.7 Metodologia general y validacion

La metodologia integra pipeline de profiling, agregacion estadistica, optimizacion, analisis de sensibilidad, consolidacion de reportes y validacion incremental. Esta secuencia garantiza trazabilidad entre medicion, modelo y evidencia doctoral.

1.8. 1.8 Contribucion cientifica

La contribucion de la tesis se plantea como integracion rigurosa entre modelado declarativo y validacion de sistemas, con protocolo experimental replicable y comparativo.

1.9. 1.9 Organizacion del documento

La monografia se organiza en capitulos que avanzan desde fundamento conceptual hacia evidencia experimental, cerrando con limites y lineas futuras.

Capítulo 2

Fundamentos Teoricos y Estado del Arte

2.1. 2.1 Entrenamiento de redes profundas y grafos computacionales

Este apartado establece la semantica de ejecucion por grafo y su relacion con dependencias de datos. La descripcion sirve de base para representar costos por nodo y por arista.

2.2. 2.2 Arquitecturas heterogeneas CPU-GPU y jerarquias de memoria

Se discute la complementariedad entre CPU y GPU en terminos de computo, memoria y latencia. La jerarquia de memoria se incorpora como restriccion central del problema de particion.

2.3. 2.3 Transferencia de datos, solapamiento y comunicacion

Se analizan costos de transferencia inter-dispositivo y su posible solapamiento con computo. Esta seccion fundamenta el termino de costo de corte en la formulacion de optimizacion.

2.4. 2.4 Estrategias de gestion de memoria

Se revisan enfoques de precision, recomputo y persistencia de activaciones que condicionan viabilidad de entrenamiento bajo presupuestos acotados.

2.5. 2.5 Optimizacion declarativa: ILP en sistemas computacionales

Se presenta el uso de ILP como marco de decision con restricciones explicitas y objetivo multicriterio, destacando trazabilidad de solucion y capacidad de auditoria.

2.6. 2.6 Estado del arte y vacios de investigacion

Se sintetizan contribuciones previas y se delimita el vacio abordado por esta tesis: cierre metodologico entre modelado, simulacion y validacion operacional reproducible.

Capítulo 3

Arquitectura Metodologica del Sistema

3.1. 3.1 Vision general del pipeline experimental

El sistema se implementa como pipeline secuencial de adquisicion, transformacion y validacion de evidencia. Cada etapa publica artefactos que alimentan la etapa siguiente.

3.2. 3.2 Estructura modular del software

Se explicita el reparto funcional entre codigo fuente, herramientas de validacion y scripts de ejecucion de campanas.

3.3. 3.3 Contrato de artefactos y trazabilidad

Se define correspondencia entre archivos de entrada, salida y metadatos de ejecucion para asegurar reproducibilidad.

3.4. 3.4 Definicion de plan y su representacion

Se describe la representacion del plan de asignacion como estructura consumible por simulador y runtime.

3.5. 3.5 Criterios de validez y riesgos metodologicos iniciales

Se documentan condiciones de calidad estadística, consistencia topológica y amenazas de validez para etapas tempranas.

Capítulo 4

Profiling Empirico para Particion Heterogenea CPU-GPU

4.1. 4.1 Motivacion empirica y preguntas de medicion

Se formulan preguntas de medicion orientadas a cuantificar costo por capa y costo de comunicacion en escenarios heterogeneos.

4.2. 4.2 Arquitectura de instrumentacion

Se documenta el mecanismo de captura de tiempos y memoria con granularidad por etapa del entrenamiento.

4.3. 4.3 Modelo de energia y carga computacional

Se presenta el tratamiento operativo de energia y proxy de carga para incorporacion en la funcion objetivo.

4.4. 4.4 Politica de precision y validez

Se describen reglas de precision soportada y verificaciones de consistencia experimental.

4.5. 4.5 Extraccion estructural del grafo

Se explica la derivacion de nodos y aristas para construir una topologia compatible con el optimizador.

4.6. 4.6 Modelo de transferencia consciente de arista

Se introduce la estimacion de costo de transferencia asociada a cortes en el grafo de ejecucion.

4.7. 4.7 Agregacion estadistica robusta

Se consolidan estadisticas robustas por capa y se incluyen indicadores de calidad muestral para auditar coeficientes.

4.8. 4.8 Validez experimental y reproducibilidad

Se establecen controles de trazabilidad, repetibilidad y limites de inferencia para campanas smoke y futuras campanas reales.

Capítulo 5

Formulacion ILP Robusta para Particion Heterogenea CPU-GPU

5.1. 5.1 Introduccion y alcance del modelo (congelado en Fase 0)

Esta seccion fija la semantica del modelo y su coherencia con el alcance metodologico aprobado.

5.2. 5.2 Notacion formal

Se introduce la notacion de conjuntos, parametros y funciones de costo utilizadas en la formulacion.

5.3. 5.3 Variables de decision

Se especifican variables binarias de asignacion y variables de corte para capturar transferencia inter-dispositivo.

5.4. 5.4 Funcion objetivo multicriterio

La funcion objetivo integra tiempo, energia y transferencia con pesos calibrables segun escenario experimental.

5.5. 5.5 Linealizaciones exactas y restricciones

Se detallan restricciones de memoria, consistencia y linealizaciones necesarias para resolver con ILP.

5.6. 5.6 Robustificacion estadistica

Se incorpora el esquema $\mu + k\sigma$ para amortiguar variabilidad de mediciones por capa.

5.7. 5.7 Integracion multi-hardware

Se documenta la fusion de perfiles de hardware cuando se dispone de multiples configuraciones.

5.8. 5.8 Complejidad y trazabilidad

Se discuten costo computacional, limites de escalabilidad y artefactos de auditoria del solver.

5.9. 5.9 Validacion comparativa contra baselines (habilitada por Fase 1)

Se presentan comparativas contra all-CPU, all-GPU y greedy con salida estructurada reproducible.

5.10. 5.10 Estudios de sensibilidad (habilitados por Fase 1)

Se analiza sensibilidad de resultados frente a k_σ , $w_{transfer}$ y presupuesto de memoria GPU.

5.11. 5.11 Ablaciones formales (habilidades por Fase 1)

Se cuantifica el aporte incremental de topología, transferencia por arista y robustificación.

5.12. 5.12 Extension avanzada: persistencia de activaciones y rematerialización (Fase 4)

Se define la extensión planificada para decisión explícita de retención de activaciones y su impacto en memoria-tiempo.

5.13. 5.13 Amenazas a la validez

Se explicitan límites de generalización, sesgos de muestreo y supuestos de modelado pendientes de validación real.

Capítulo 6

Ejecucion Hibrida, Simulacion y Validacion Experimental

6.1. 6.1 Introduccion: cierre del bucle planificacion-ejecucion

Se formaliza la transicion desde solucion de optimizacion hacia comportamiento operacional verificable.

6.2. 6.2 Representacion formal del plan de ejecucion (Fase 2)

Se define la estructura de plan, sus invariantes y su semantica de consumo por componentes runtime.

6.3. 6.3 Simulador hibrido: arquitectura y validacion topologica (Fase 2)

Se describe el diseno del simulador y los chequeos de coherencia sobre el DAG de ejecucion.

6.4. 6.4 Estudio de prediccion: latencia, memoria y costos de transferencia (Fase 2)

Se especifican metricas de prediccion y metodologia para evaluacion determinista previa a ejecucion real.

6.5. 6.5 Implementacion del ejecutor hibrido en PyTorch (Fase 3)

Se documentara la implementacion operacional de la politica de asignacion en entrenamiento real.

6.6. 6.6 Baselines reales y comparativos experimentales (Fase 3)

Se establecera comparacion sistematica frente a politicas de referencia en entorno fisico.

6.7. 6.7 Prediccion frente a observacion: contraste operacional (Fase 3)

Se cuantificara el error de prediccion y su distribucion por regimen de carga.

6.8. 6.8 Exactitud final del modelo y estabilidad de convergencia (Fase 3-5)

Se evaluara impacto de la ejecucion hibrida sobre calidad final del entrenamiento.

6.9. 6.9 Extensiones con persistencia de activaciones y scheduling asincrono (Fase 4)

Se integraran extensiones avanzadas de memoria y planificacion para cerrar la propuesta completa.

6.10. 6.10 Analisis integrado de resultados y limites experimentales (Fase 5)

Se sintetizaran resultados globales y restricciones metodologicas observadas en campana doctoral.

Capítulo 7

Conclusiones, Limites y Trabajo Futuro

7.1. 7.1 Sintesis de resultados frente a la hipotesis

Se consolidara evidencia de mejora frente a baselines y consistencia entre prediccion y observacion.

7.2. 7.2 Contribuciones metodologicas y de sistemas

Se delimitara el aporte original en instrumentacion, modelado y validacion operacional.

7.3. 7.3 Limites del modelo y del protocolo experimental

Se identificaran supuestos y limites de transferibilidad en escenarios de hardware heterogeneo.

7.4. 7.4 Lineas de trabajo futuro

Se proyectaran extensiones del modelo, escalamiento experimental y consolidacion doctoral final.